

Improving short-term rain prediction by deep neural networks

Anna Kapitánová

ČVUT – FIT

kapitann@fit.cvut.cz

1. prosince 2022

1 Úvod

Tato semestrální práce se zabývá krátkodobou predikcí srážek. Na naší fakultě se výzkumem této problematiky dlouhodobě zabývá tým výzkumníků z laboratoře DataLab ve spolupráci s firmou Meteopress. Moje práce bude navazovat na jejich dosavadní výsledky v této oblasti [1]. Úkolem bude, srovnání úspěšnosti predikce architektury MWNet (Meteopress Weather Net) s použitím PredRNN [5] oproti stávající ConvLSTM [4].

2 Data


Dataset je sestaven z radarových snímků, získaných v rámci programu OPERA [2]. Jedná se o naměřená data z let 2019 a 2020. Časový rozdíl mezi jednotlivými snímky je 10 minut (až na výjimky způsobené výpadkem nebo poškozením snímků – pouze jednotky snímků). Jedná se o snímky pořízené radary v oblasti České Republiky. Trénovací dataset má 150 000 záznamů, validační 3964.

3 Rešerše

Detekce srážek spočívá v předpovědi zasažené oblasti a předpovědi jejich trvání, v literatuře se setkáváme s pojmenováním Spatio-temporal prediction (časoprostorová predikce). Obecně se problematikou predikce počasí zabývá oblast zvaná Numerical Weather Prediction (NWP). Ta k predikci počasí využívá série rovnic, které popisují fyzikální úkazy, jež mají vliv na atmosférické jevy. Mezi takové jevy patří např. tlak, hustota atmosféry, vlhkost, teplota, apod. Fyzikální jevy, které mají vliv na predikci počasí, mohou být popsány pomocí parciálních diferenciálních rovnic (Partial differential equation – PDE) [1]. Existují ale i vlivy, které tyto rovnice nepopisují, ty v rámci predikce musíme také brát v potaz.

Architektura PhyDNet, popsaná ve studii [3], byla původně navržena pro predikci následujících snímků videa. Jedná se o two-branch hlubokou rekurentní

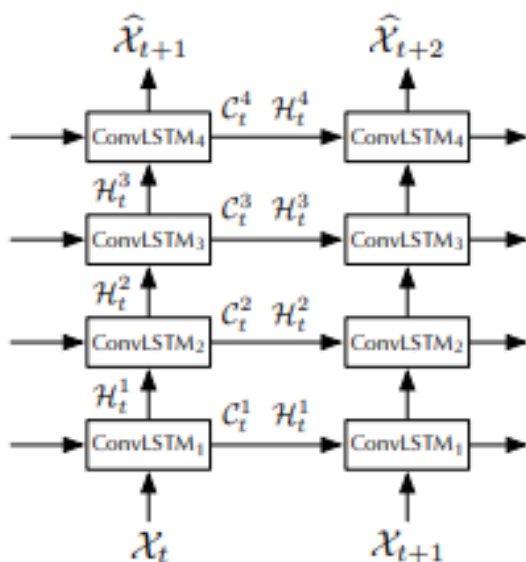
neuronovou síť, která odděluje fyzikální dynamiku mezi jednotlivými snímky videa, popsanou pomocí PDE, od neznámých faktorů. První část architektury, která se zabývá fyzikální dynamikou, se nazývá PhyCell. Druhá část, která zaštituje neznámé faktory, je tvořena ConvLSTM. Architekturu PhyDNet zobrazuje obrázek 1.



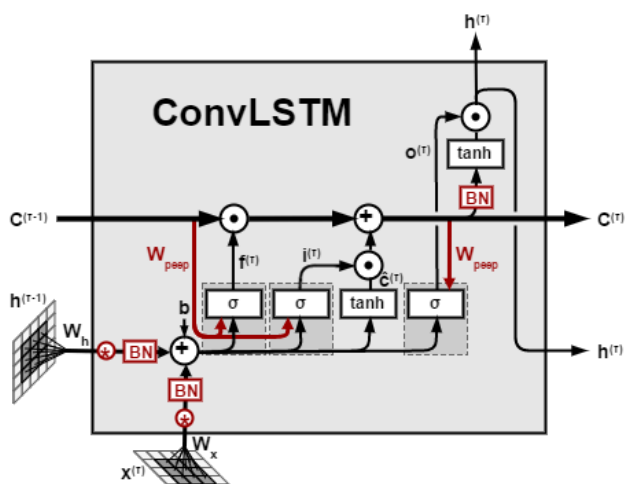
Obrázek 1: Architektura PhyDNet

Problematikou předpovědi srážek se zabývali také výzkumníci ve studii [4]. V této práci byla také představena architektura ConvLSTM, tedy konvoluční LSTM. Jedná se o verzi LSTM neuronové sítě přizpůsobenou pro prostorová data. Klasická LSTM vykazuje pro prostorová data velkou míru redundance, způsobenou plně propojenými vrstvami na přechodech input-to-state i state-to-state. Architekturu ConvLSTM zachycuje obrázek 2. Vnitřek jedné ConvLSTM jednotky je zobrazen na obrázku 3.

PredRNN byla představena v práci [5]. Tato architektura navazuje na architekturu ConvLSTM a přináší vylepšení pro časoprostorovou predikci. Hlavní rozdíl spočívá v tom, že memory state (udrží paměť jednotky u ConvLSTM) již není uzavřen pouze uvnitř konkrétní PredRNN jednotky, ale může se

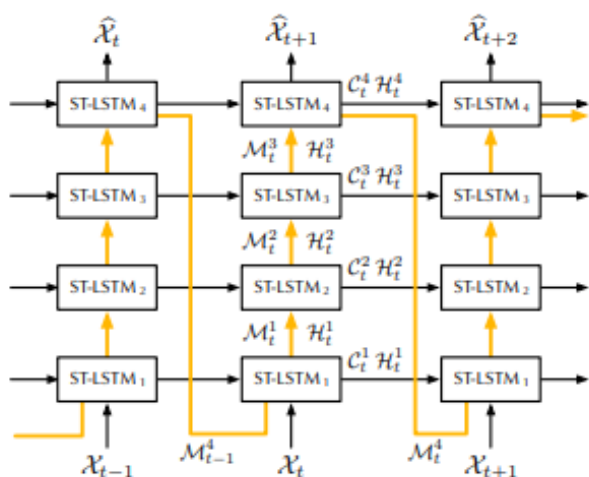


Obrázek 2: Architektura ConvLSTM

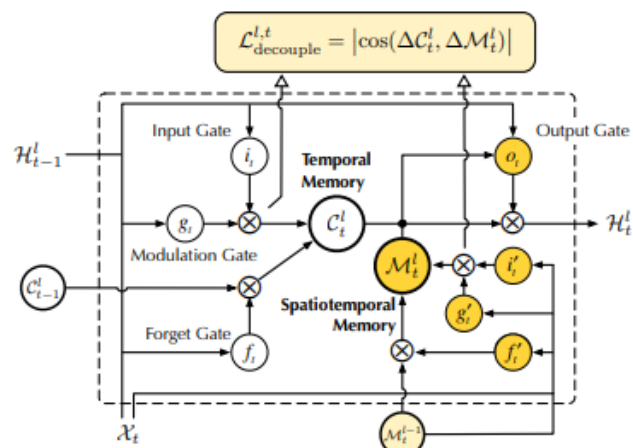


Obrázek 3: Vnitřek ConvLSTM jednotky

širit napříč jednotkami, jak je zobrazeno na obrázku 4. Vnitřek jednotky je zobrazen na obrázku 5.



Obrázek 4: Architektura PredRNN



Obrázek 5: Vnitřek PredRNN jednotky

4 Metody

Jedná se o regresní úlohu, která přijímá na vstupu 2D pole radarových snímků a jejím úkolem je predikce K budoucích snímků na základě J předchozích. Momentální architektura MWNet je inspirována architekturou PhyDNet. Hlavní prvky architektury MWNet jsou deep convolutional encoder (na vstupu) a decoder (na výstupu), vnitřek se architektury větví na dvě části:

- PhyCell – modeluje fyzikální část predikce pomocí parciálních diferenciálních rovnic,
- Deep ConvLSTM – modeluje neznámé faktory.

5 Momentální stav


Bohužel nemůžu poskytnout odkaz na repozitář s kódy, neboť jsou vlastnictvím DataLabu. Zatím se mi ale povedlo natrénovat architekturu s ConvLSTM a naměřit její přesnost na validační sadě dat. Tabulka 6 zachycuje naměřené výsledky různými metrikami na validační sadě dat. Obrázek 7 zobrazuje původní radarový snímek v čase t, obrázky 8, 9, 10, 11, 12, 13, 14 zobrazují predikci srážek v čase t+x min.

Validate metric	DataLoader 0
0 moment	0.02021481655538082
C _{SI} 0.13	0.3740144968032837
CSI 0.67	0.286948561668396
img_loss	0.30587077140808105
loss	0.32608547806739807
mae	0.1517641395330429
mse	0.09940988570451736
prediction_mean	-0.07776696234941483


Obrázek 6: Výsledky na validační sadě dat

Reference


- [1] Matej Choma. Improving deep learning precipitation nowcasting by using prior knowledge, 2022.
- [2] Eumetnet. Opera. <https://www.eumetnet.eu/activities/observations-programme/current-activities/opera/>.
- [3] Vincent Le Guen and Nicolas Thome. Disentangling physical dynamics from unknown factors for unsupervised video prediction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11474–11484, 2020.
- [4] Xingjian Shi, Zhouong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional lstm network: A machine learning approach for precipitation nowcasting. *Advances in neural information processing systems*, 28, 2015.
- [5] Yunbo Wang, Haixu Wu, Jianjin Zhang, Zhifeng Gao, Jianmin Wang, Philip Yu, and Mingsheng Long. Predrnn: A recurrent neural network for spatiotemporal predictive learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022.




Obrázek 7: Radarový snímek v čase t



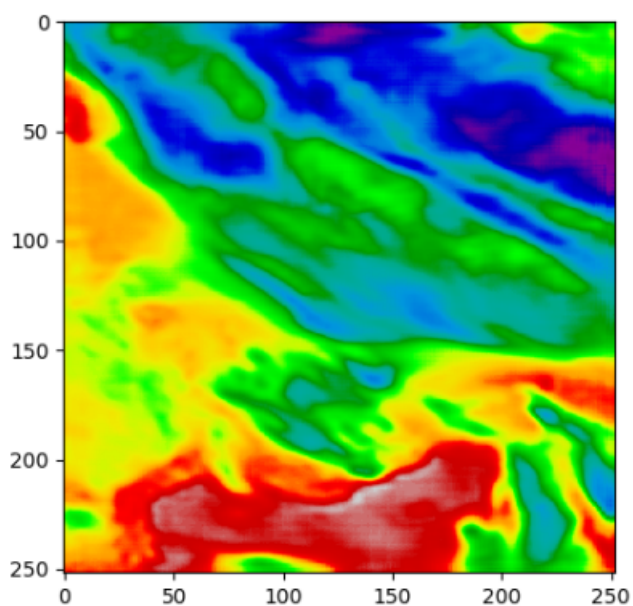
Obrázek 9: Predikce rad. snímku v čase $t+20$ min




Obrázek 8: Predikce rad. snímku v čase $t+10$ min




Obrázek 10: Predikce rad. snímku v čase $t+30$ min




Obrázek 11: Predikce rad. snímku v čase $t+40$ min



Obrázek 13: Predikce rad. snímku v čase $t+60$ min



Obrázek 12: Predikce rad. snímku v čase $t+50$ min



Obrázek 14: Predikce rad. snímku v čase $t+70$ min