

Improving short-term rain prediction by deep neural networks

Anna Kapitánová

ČVUT – FIT

kapitann@fit.cvut.cz

17. ledna 2023

1 Úvod

Tato semestrální práce se zabývá krátkodobou predikcí srážek. Na naší fakultě se výzkumem této problematiky dlouhodobě zabývá tým výzkumníků z laboratoře DataLab ve spolupráci s firmou MeteoPress. Moje práce bude navazovat na jejich dosavadní výsledky v této oblasti [2]. Úkolem bude, srovnání úspěšnosti predikce současné architektury s použitím PredRNN [6] oproti stávající ConvLSTM [5].

2 Data

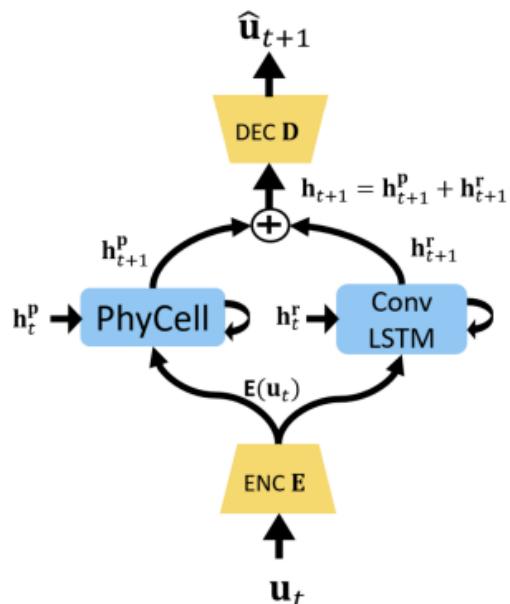
Dataset je sestaven z radarových snímků, získaných v rámci programu OPERA [3]. Jedná se o naměřená data z let 2019 a 2020. Časový rozdíl mezi jednotlivými snímkami je 10 minut (až na výjimky způsobené výpadkem nebo poškozením snímků – pouze jednotky snímků). Trénovací dataset má 150 000 záznamů, validační 3964. Jednotlivé snímkы mají velikost 252 x 252 a skládají se z 11 channelů.

3 Rešerše

Detekce srážek spočívá v předpovědi zasažené oblasti a předpovědi jejich trvání, v literatuře se setkáváme s pojmenováním Spatio-temporal prediction (časoprostorová predikce). Obecně se problematikou predikce počasí zabývá oblast zvaná Numerical Weather Prediction (NWP). Ta k predikci počasí využívá série rovnic, které popisují fyzikální úkazy, jež mají vliv na atmosférické jevy. Mezi takové jevy patří např. tlak, hustota atmosféry, vlhkost, teplota, apod. Fyzikální jevy, které mají vliv na predikci počasí, mohou být popsány pomocí parciálních diferenciálních rovnicích (Partial differential equation – PDE) [2]. Existují ale i vlivy, které tyto rovnice nepopisují, ty v rámci predikce musíme také brát v potaz.

Architektura PhyDNet, popsána ve studii [4], byla původně navržena pro predikci následujících snímků videa. Jedná se o two-branch hlubokou rekurentní

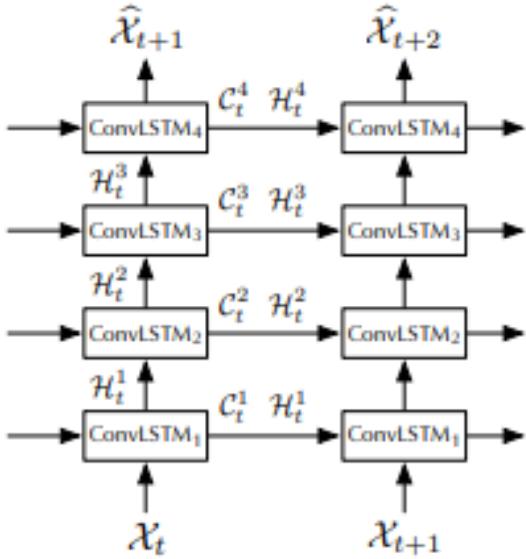
neuronovou síť, která odděluje fyzikální dynamiku mezi jednotlivými snímkami videa, popsanou pomocí PDE, od neznámých faktorů. První část architektury, která se zabývá fyzikální dynamikou, se nazývá PhyCell. Druhá část, která zaštiťuje neznámé faktory, je tvořena ConvLSTM. Architekturu PhyDNet zobrazuje obrázek 1.



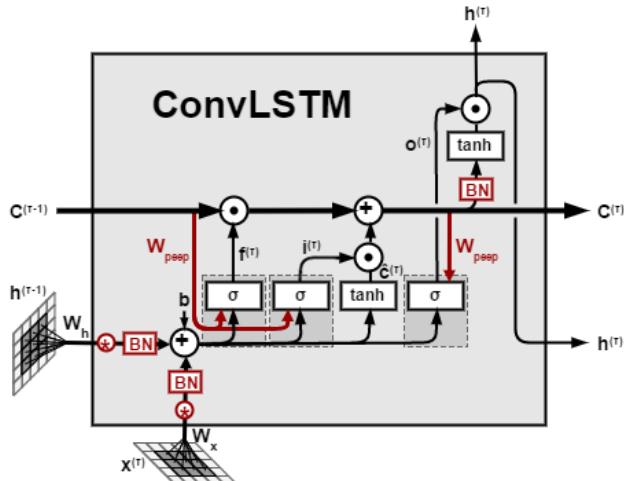
Obrázek 1: Architektura PhyDNet

Problematikou předpovědi srážek se zabývali také výzkumníci ve studii [5]. V této práci byla také představena architektura ConvLSTM, tedy konvoluční LSTM. Jedná se o verzi LSTM neuronové sítě přizpůsobenou pro prostorová data. Klasická LSTM vykazuje pro prostorová data velkou míru redundance, způsobenou plně propojenými vrstvami na přechodech input-to-state i state-to-state. Architekturu ConvLSTM zachycuje obrázek 2. Vnitřek jedné ConvLSTM jednotky je zobrazen na obrázku 3.

PredRNN byla představena v práci [6]. Jedná se prediktivní rekurentní neuronovou síť. Její architektura navazuje na architekturu ConvLSTM a přináší vylepšení pro časoprostorovou predikci. Myslenka PredRNN spočívá v tom, že časoprostorová predikce by si měla pamatovat, jak prostorové jevy,



Obrázek 2: Architektura ConvLSTM



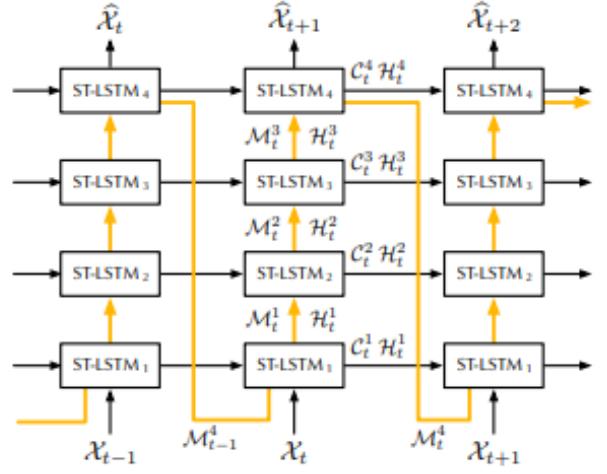
Obrázek 3: Vnitřek ConvLSTM jednotky

tak proměnlivost v čase v jednotné paměti. Stav paměti, tak není uzavřen pouze v rámci jedné LSTM jednotky, ale šíří se ve dvou směrech. Vertikálně (přes jednotlivé vrstvy) a také přes jednotlivé stavy horizontálně, jak je zobrazeno na obrázku 4, kde oranžová barva zobrazuje časoprostorovou paměť a šedá standardní časový tok. Vnitřek jednotky je zobrazen na obrázku 5.

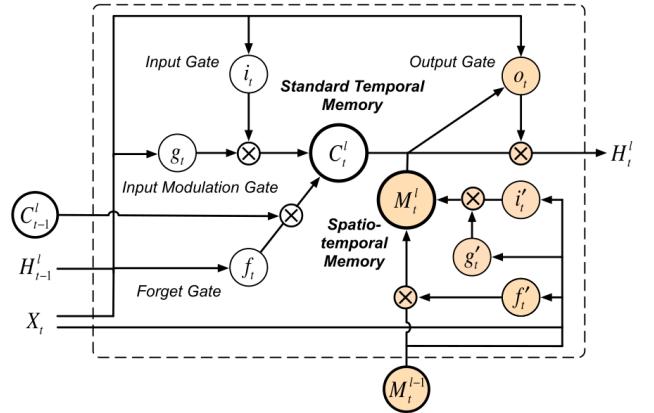
4 Metody

Jedná se o regresní úlohu, která na základě J vstupních radarových snímků predikuje K budoucích. Momentální architektura je inspirována architekturou PhyDNet. Hlavní prvky architektury jsou deep convolutional encoder (na vstupu) a decoder (na výstupu), vnitřek se architektury větví na dvě části:

- PhyCell – modeluje fyzikální část predikce pomocí parciálních diferenciálních rovnic,



Obrázek 4: Architektura PredRNN



Obrázek 5: Vnitřek PredRNN jednotky

- Deep ConvLSTM – modeluje neznámé faktory.

5 Výsledky

Nejprve jsem natrénovala původní architekturu s ConvLSTM a naměřila přesnost zadánymi metrikami. Celkem bylo trénováno 12 epoch. Tabulka 6 zachycuje naměřené výsledky různými metrikami na validační sadě dat pro původní architekturu.

Následně jsem naprogramovala PredRNN a nasadila ji do původní architektury, tak jak byla představena v práci [6]. Při implementaci jsem z vycházela z této práce [1]. Architektura se skládá ze tří skrytých vrstev o velikosti 64, 64 a 64. Všechny konvoluce v PredRNN jednotkách používají kernel velikosti 3 x 3, stride 1. Dalším úkolem bylo upravenou síť natrénovat. Maximum epoch jsem nechala nastavených na 50, stejně jako tomu bylo u původní architektury. Zastavovací podmínu jsem také ponechala na patience rovno 10 epochám. Jako optimalizační technika je využit Adam optimizer s learning rate 0.001. Kvůli časové náročnosti trénování, mohu zatím pre-

Validate metric	DataLoader 0
θ_moment	0.02021481655538082
CSI_0.13	0.37400373816490173
CSI_0.67	0.2869494557380676
SSIM	0.6485072374343872
img_loss	0.3058716356754303
loss	0.32608652114868164
mae	0.15176934003829956
mse	0.09942048788070679
prediction_mean	-0.07779501378536224

Obrázek 6: Výsledky architektury s ConvLSTM na validační sadě dat

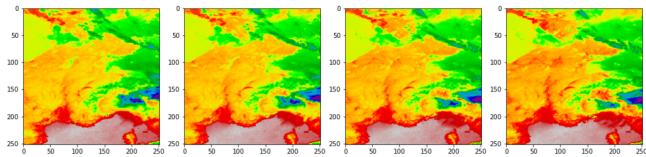
zentovat pouze výsledky predikce po 11 epochách trénování. Trénování sítě nicméně stále pokračuje a je tak možné, že po plném dotrénování budeme moci pozorovat ještě jisté zlepšení přesnosti. Tabulka 7 zobrazuje naměřené výsledky metrik po 11 epochách.

Validate metric	DataLoader 0
θ_moment	0.015404103323817253
CSI_0.13	0.3695826530456543
CSI_0.67	0.28631651401519775
SSIM	0.652728796005249
img_loss	0.28903067111968994
loss	0.30443474650382996
mae	0.15294982492923737
mse	0.0997876450419426
prediction_mean	-0.08482583612203598

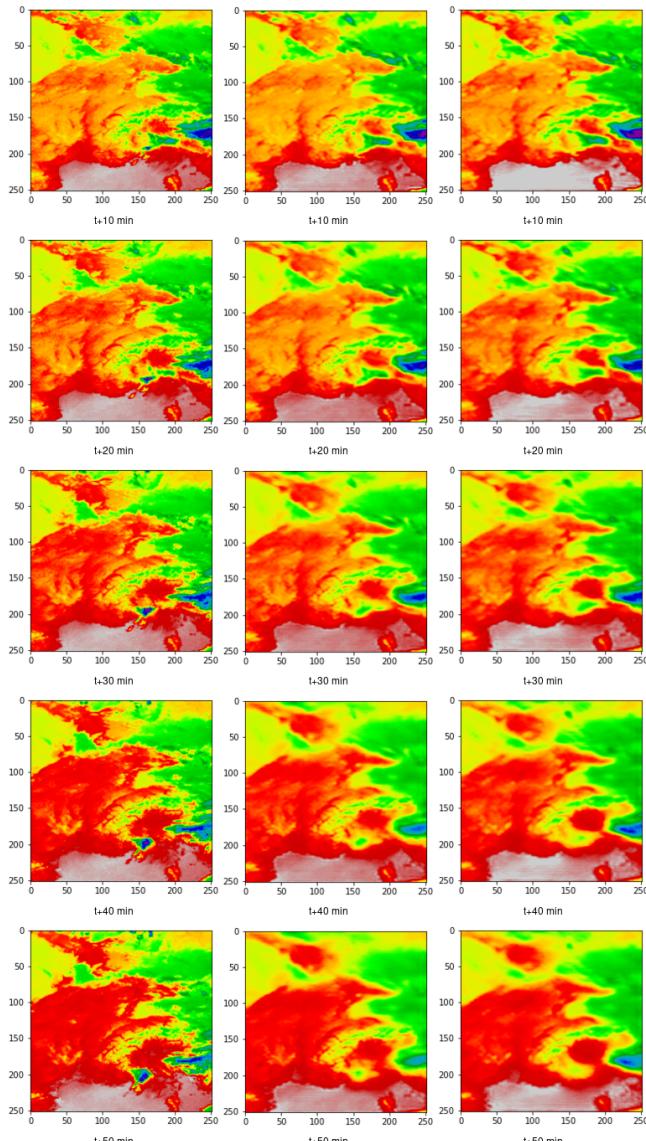
Obrázek 7: PredRNN výsledky na validační sadě dat

Obrázek 8 zobrazuje sérii čtyř radarových snímků na vstupu na základě, kterých byla provedena predikce. Srovnání predikcí v časech t+x minut se skutečnými radarovými snímkami v jednom channelu, zobrazují obrázky 9 a 10.

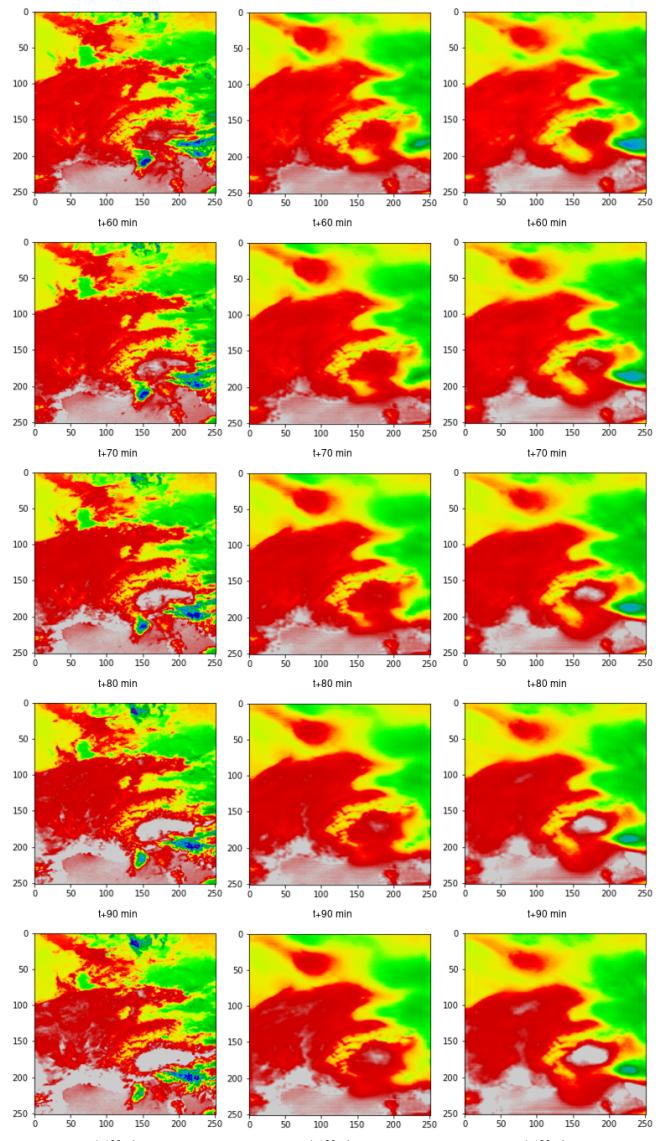
Výsledky metrik, jak je vidět v tabulkách 6 a 7, odpovídají momentálně lepší performaci původní architektury ConvLSTM proti PredRNN. Z prozatímního průzkumu predikovaných snímků se domnívám, že zejména u kratších predikcí architektura obsahující PredRNN disponuje lépe odpovídajícím detailům s původními snímkami naměřenými radarem. V pozdějších predikcích, ale stejně jako na přiložených obrázcích vidíme lepší výkon architektury ConvLSTM co do odhadu intenzity srážek. Toto pozorování, ale může být subjektivní.



Obrázek 8: Vstupní radarové snímky



Obrázek 9: Porovnání skutečných radarových snímků v časech $t+10\text{min}$ až $t+50\text{min}$ (sloupec vlevo) se předpověďmi PredRNN (sloupec uprostřed) a ConvLSTM (sloupec vpravo)



Obrázek 10: Porovnání skutečných radarových snímků v časech $t+60\text{min}$ až $t+100\text{min}$ (sloupec vlevo) se předpověďmi PredRNN (sloupec uprostřed) a ConvLSTM (sloupec vpravo)

Reference

- [1] Predrnn: A recurrent neural network for spatiotemporal predictive learning (tpami 2022). <https://github.com/thumt/predrnn-pytorch>.
- [2] Matej Choma. Improving deep learning precipitation nowcasting by using prior knowledge, 2022.
- [3] Eumetnet. Opera. <https://www.eumetnet.eu/activities/observations-programme/current-activities/opera/>.
- [4] Vincent Le Guen and Nicolas Thome. Disentangling physical dynamics from unknown factors for unsupervised video prediction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11474–11484, 2020.
- [5] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional lstm network: A machine learning approach for precipitation nowcasting. *Advances in neural information processing systems*, 28, 2015.
- [6] Yunbo Wang, Haixu Wu, Jianjin Zhang, Zhifeng Gao, Jianmin Wang, Philip Yu, and Mingsheng Long. Predrnn: A recurrent neural network for spatiotemporal predictive learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022.